

面向动态智能体任务的按步执行与信息共享

Yaojunzhe Zhai¹ · Chao-Hsien Hsieh²

¹ Monash University Malaysia ² Xi'an International University

摘要

智能体处理本地资料时，运行中新增的步骤可能需要云端模型或外部工具。沿用完整上下文会扩大共享范围，固定裁剪又可能遗漏后续输入。本文介绍按步执行与信息共享原型：由本地控制器选择登记的执行方式和接收方视图，在发送前核对来源、能力与授权，状态变化后保留仍有效的计算结果。双栏界面将任务步骤与实际接收内容对应展示。24 道公开财务问题产生 48 份真实模型计划；受控配对执行中，结果复用使 HTTP 算子调用从 331 次降至 261 次。零售与航空多轮开发任务进一步检验原生业务操作和本地引用绑定。实验分别报告任务答案、执行一致性与实际外发，避免把成功执行等同于语义正确。

关键词：智能体执行；接收方视图；累计披露；局部修复；系统演示。

1 问题与系统目标

企业智能体常先读取内部资料，再向云端模型或工具提出请求。以合同检查为例，解释条款需要条款内容，核算金额可能只需几个数值，后续检索又需要新的查询条件。任务开始时通常无法确定所有步骤，因此，每次新增操作都需要重新判断在哪里执行、当前接收方需要哪些输入。

即使请求字段没有变化，原来的执行方式也可能失效。例如，本地计算能力被撤销后，待执行步骤必须改用外部服务；

已经算出的、来源仍有效的中间结果却无需重复计算。系统需要同时管理执行候选、接收方已见信息与结果来源，而不能仅在任务开始时做一次脱敏。

PlanTwin [1] 通过规划抽象和本地门控限制云端观察；PrivScope [2] 按子任务控制披露范围与抽象程度；MINIM [3] 根据敏感性和任务必要性处理界面观察。这些工作已覆盖本地裁剪、抽象与披露控制，本文不将这些组成技术单独作为首次提出的方法。

本演示面向智能体应用开发者与数据管理员，将上述决策落实为可检查的执行过程：数值路径比较登记的等价输入并复用有效结果；业务路径以不透明引用保留本地精确值，在执行具体工具时完成绑定。两条路径共用“模型提案—本地核验—实际执行—接收记录”的观察方式，其适用条件和证据分别报告。

系统的展示重点是决策与实际数据流之间的对应关系。观众可以检查模型提出的计算，改变本地能力或源值，比较哪些步骤被重算，并直接查看接收端收到的内容。本文贡献为具备可复核执行记录的研究原型，以及对复用、规划和引用检查作用的分项评估；不声称已解决任意自然语言任务的最小充分信息判定。




图 1 按步执行的系统结构。原始资料保留在本地；模型与工具通过登记出口交互。新步骤或状态变化触发重新判定，外部结果写回本地状态。

2 逐步执行与接收方视图

2.1 执行候选与披露历史

版本化状态 S 保存源值、授权与本地能力。数值路径中，模型先读取不含业务数值的表结构，再提交计算图；控制器只接受六种登记算子组成的前向程序，所有节点都须参与最终结果。候选 a 指定执行位置、接收方 r 和输入视图 V ；视图可以是原值与子表达式，也可以是已算出的直接操作数。

一次披露以接收方、源字段或派生表达式及来源版本的指纹标识。令 $E(a)$ 为候选披露项， H 为确认发送的集合；本地执行的 $E(a)$ 为空。每次得到匹配接收记录后更新：

$$H_{t+1} = H_t \cup E(a_t) \quad (1)$$

同一字段发送给不同接收方分别计数；派生值也计数。源版本变化后再次发送计为新项。 H 不随重试或局部修复回退。该指标描述显式披露，不度量敏感性，也不排除接收方通过多个值联合推断。

2.2 比较当前已知的后续方案

设 Q 为当前已知待执行图， $P(Q, S)$ 为满足授权、能力和剩余预算的候选组合； $W(p)$ 是本地及接收端实际求值的算子数， $T(p)$ 是发送的数值字段次数。原始字段重复发送仍计入 T ，新增披露集合为：

$$D(p) = (\bigcup_{a \in p} E(a)) \setminus H \quad (2)$$
$$p^* = \arg \min_{p \in P(Q, S)} \text{lex}(|D(p)|, W(p), T(p)) \quad (3)$$

式 (3) 依次比较不同披露项、算子求值与传输字段。阶段开始时，以相同状态下逐步贪心的传输量为基准设预算 B ；默认不增加字段，敏感性设置允许增加 10% 或 25%。执行每一步都扣减同一余额，不能重新取得整份额度。

$$B = [(1 + \rho)T(p_g)] \quad (4)$$

同一深度的标签记录披露集合、累计求值与传输 (E, w, b) 。下式成立时第二个标签可被剪枝：

$$E_1 \subseteq E_2 \wedge w_1 \leq w_2 \wedge b_1 \leq b_2 \quad (5)$$

若候选输出等价且后续可行性不依赖表示，追加同一后缀保持集合包含与两项成本关系，因此剪枝不会丢失受限问题的最优解。未来派生值用表达式及源版本标识，无需预先计算其数值。最坏搜索仍为指数级，超过 4,096 个标签明确失败。

一个逐步选择失效的例子

设两个步骤均可向服务甲发送同一对原值 $\{x, y\}$ ；另一条路径向服务乙分别发送一个派生值 $\{u\}$ 与两个不同派生值 $\{v, w\}$ 。逐步贪心先选乙，只披露一项；第二步无论选哪条路径，累计都至少为三项。后续规划连续选择甲，累计只有两项，但会传输四个字段。该例说明为什么披露集合与传输次数须分衡。

2.3 核验决策，而不只核验请求字段

控制器区分两类依赖：源值决定结果是否仍有效；能力和授权决定执行方式是否仍可行。发送前，两类依赖的记录版本都必须与当前版本一致：

$$\Delta = \Delta_{\text{值}} \cup \Delta_{\text{规划}}, \forall k \in \Delta: v(k) = v_{\text{当前}}(k) \quad (6)$$

源版本、当前能力和授权在序列化前同步检查；状态变化后重新选择剩余步骤，缓存仅按值依赖判断是否保留。受控版本往返测试使用单调版本号。已失效结果不得作为新请求的操作数，未用源字段改变则不使该结果失效。

算法 1 面向接收方的后续规划与局部修复

Input: versioned state S , graph Q , registry R , slack ρ

Output: checked results C and disclosure history H

```
1:  $C \leftarrow \emptyset$ ;  $H \leftarrow \emptyset$ ;  $B \leftarrow \text{UNSET}$ 
2: while  $Q$  is not empty do
3:   if StateChanged( $S$ ) then
4:      $C \leftarrow \text{KeepValidPureResults}(C, S)$ 
5:      $Q \leftarrow \text{Pending}(Q, C)$ ;  $B \leftarrow \text{UNSET}$ 
6:    $A \leftarrow \text{EquivalentAlternatives}(S, Q, R)$ 
7:   if  $B = \text{UNSET}$  then
8:      $B \leftarrow \text{floor}((1 + \rho) \times \text{Fields}(\text{Greedy}(A, H)))$ 
9:    $p \leftarrow \text{BudgetFrontier}(A, H, B)$ 
10:  if  $p$  is infeasible then return BLOCKED
11:   $a \leftarrow \text{First}(p)$ ; CheckCurrent( $S, a$ )
12:  if  $a.\text{recipient} = \text{local}$  then  $y \leftarrow \text{Evaluate}(a)$ 
13:  else
14:    bytes  $\leftarrow \text{Serialize}(a)$ ; CheckCurrent( $S, a$ )
15:     $y, \text{receipt} \leftarrow \text{SendOnce}(\text{bytes})$ 
16:    VerifyReceipt(receipt, bytes)
17:     $H \leftarrow H \cup \text{DisclosureTokens}(a)$ 
18:     $B \leftarrow B - \text{NumericFields}(a)$ 
19:     $C \leftarrow \text{SavePureResult}(C, y, \text{SourceDeps}(a))$ 
20:     $Q \leftarrow \text{RemoveCompleted}(Q, a)$ 
21: return  $C, H$ 
```

算法 1 在每个状态稳定阶段维持一个余额。阶段内，剩余旧方案为下一次受限选择提供可行解；累计实际发送字段因而不超过阶段预算。新的干预会开启新阶段，这个局部界限不能替代整轮任务的实测传输量。

接收端记录原始字节、摘要与结果，核验器逐请求重算。新模型图实验使用同一 Node 进程内的回环 HTTP 监听器；真实模型请求由另一个代理保存供应商载荷与响应摘要。它们均不构成供应商签名回执或生产分布式事务证明。

自动复用仅限登记的无副作用计算。接收授权撤销不能收回既往披露；网络返回不确定时停止，不假设未获回执就没有信息外发。任意脚本、带副作用工具及不可信控制器均不在保证范围内。

2.4 业务绑定与信息补充

业务适配器将六类登记字段替换为不透明引用，在原生工具调用前恢复精确值，并可检查目标参数和来源当前值；改变业务状态的操作另需本地确认。独立的信息补充执行器只接受已登记的结构需求，在本地完成、派生结果与获准原值之间选择，拒绝模型自行扩大的字段请求。它已通过构造案例的真实 HTTP 检查，尚未接入本文批量模型实验；其有限契约不能判定自由文本是否充分。



图 2 公开财务表格的实际执行界面。① 从保存的真实模型回复创建计算步骤；② 受控撤销本地能力，保留已完成结果；③ HTTP 接收端收到中间值与所需源值。截图为冻结批次中一个计划的独立重执行，裁去导航并添加编号，不增加测试样本数。

3 交互演示

界面沿用客户端的双栏任务布局。左侧执行自动推进，右侧随选中步骤展示接收方、发送内容、保留字段与接收记录。观众可暂停跟随检查旧请求，再回到当前步骤；无需逐步点击才能完成任务。展示节奏单独放慢，不计入实验耗时。

场景一展示公开财务表格。模型通过真实工具调用读取表结构，提交“相加、相加、相除”的计算图。观众运行保存的计划；首步完成后，预定事件撤销本地加減能力。系统保留首步结果，把后续计算交给 HTTP 算子。切换完整重跑，首步会重复执行。右栏显示这一差异对应的实际请求，观众无需从最终统计数字猜测发生了什么。

场景二比较已用与未用源值更新。前者使相关结果失效，后者保留已有计算。右侧显示发送的原值或中间值，以及本阶段剩余预算。全本地设置展示不需要外部数值服务的情况；混合能力是受控配置，不表示加減乘除天然需要云端。两种干预均由程序执行，不是截图中的装饰性状态。

无密钥模式重用真实模型计划，重新执行计算与 HTTP 请求。现场模型调用使用读者自己的密钥；密钥不随仓库发布。合同案例保留模型运行中提出检索步骤的记录。零售和航空适配器提供独立批次与离线复核命令，尚未并入图 2 的可视界面，因此不将其描述为已完成的页面演示。

4 实验设计

数值实验在模型调用前冻结提示词、执行器、评价器与事件安排。FinQA [4] 子集包含 24 题、24 份此前未用的公司年度报告，原 test 与 dev 划分各 12 题；兼容筛选限定可由表格和登记算子处理的问题，另四题仅作开发。执行器不读取答案标签。

每题生成两份 DeepSeek 计划，每份使用两次工具调用，共 48 份计划、96 次请求。各计划在五种条件下比较完整重跑、复用加贪心、无预算后续规划及三档预算方法。五种条件为全本地、混合能力稳定、已用值更新、未用值更新和能力撤销。每种方法 240 次执行，共 1,440 次；它们共享计划，不是独立模型样本。

业务开发实验使用 τ^2 -bench [5] 的三个零售和三个航空训练任务，保留原生工具、状态和参数校验，增加统一的本地确认层。比较完整工具返回、普通引用与受限引用；每种方法最后一批各执行六个任务。开发过程中共 54 次尝试、952 次真实调用，所有失败保留。这六个任务被反复使用，不能作为独立测试集。

数值评价区分模型答案与按图执行一致性，并按源问题聚类统计。业务评价检查完整数据库是否与参考操作所得状态一致，不冒充官方综合得分。另固定普通与受限引用的全部末批轨迹，在两个新数据库中仅切换引用检查；若结果分歧即停止，避免把后续保存动作误当成有效反事实。




图 3 新模型图实验，每种方法 240 次配对执行。a、b：实际 HTTP 调用与数值字段传输；c：按干预条件拆分；d：R、G、F 分别为重跑、贪心与后续规划，后三项为传输预算设置。本批次的五种修复方法结果相同，不支持额外规划收益。

5 结果与讨论

数值路径中，48 份计划均可执行，但原问题标签一致性仅为 28/48。结果复用将 HTTP 调用从 331 次降至 261 次，减少 21.1%；数值字段传输从 724 次降至 500 次。按 24 题聚类的探索性自助区间为 [19.1%, 23.8%]。收益主要来自能力撤销和未用源值变化后的结果保留。

图 3 中，贪心、后续规划和三档预算的披露项及传输字段均相同，未观察到规划的额外收益。按图执行一致也不意味着答案正确：错误涉及年份选择、差值方向和百分比单位；两道疑似标签错误的平均数题仍保留原评分，未据此提高结果。

表 1 原生业务开发任务的未批结果

方法	状态一致	原值出现	检查拒绝
完整返回	5/6	111	0
普通引用	4/6	0	0
受限引用	6/6	0	0

“原值出现”仅统计发给规划模型的不同工具消息中六类登记字段的非空原值，排除用户对话和确认模拟器；它不是语义泄露率。普通引用同样将该计数降为零，不能把这一效果归于新增用途检查。

为核查表 1 的完成差异，对两种引用方法的 12 条轨迹、107 个业务提案逐一切换检查。两侧调用和最终状态全部一致。这说明本批次没有体现新增检查的执行收益；不同采样对话中的 4/6 与 6/6 不足以建立因果关系。

6 适用范围与开放实现

系统已实现可视执行、版本核验、有效结果复用和原生业务工具适配。证据支持这些组件能够运行并被复核，也支持受控变化下的复用收益；尚不支持后续规划或受限引用优于强对照。登记视图的等价性来自本地规则，不能推广为自动理解任意业务内容。

实验仅使用一个模型。业务任务的用户与确认环节也由 DeepSeek 模拟，后者可见原始参数，因此不能宣称模型供应商完全看不到原值。数据库一致性不覆盖全部业务政策；人类对自由文本解释和操作合理性的评阅尚未完成。软件检查、开发样本与独立质量评价不能互相替代。

开源包独立于商业客户端，包含双语页面、任务输入、真实模型记录、接收记录和离线核验器。构造的信息补充案例可重跑三阶段决策与两次 HTTP 发送，但不计入模型实验。所有失败、无收益结果和版本来源均保留；读者可以追溯正文数字并复核界面所示过程。

代码与复现：<https://github.com/Zane-0260907/stepwise-disclosure-demo>

参考文献

- [1] G. Yu 等. PlanTwin: Privacy-Preserving Planning Abstractions for Cloud-Assisted LLM Agents. arXiv:2603.18377, 2026.
- [2] S. R. Seeam 等. PrivScope: Task-scoped Disclosure Control for Hybrid Agentic Systems. arXiv:2605.16630, 2026.
- [3] H. Yu 等. MINIM: Privacy-Aware Minimal View for Agents via Trusted Local Sanitization. arXiv:2606.13949, 2026.
- [4] Z. Chen 等. FinQA: A Dataset of Numerical Reasoning over Financial Data. EMNLP, 2021, 3697–3711.
- [5] V. Barres 等. τ^2 -Bench: Evaluating Conversational Agents in a Dual-Control Environment. arXiv:2506.07982, 2025.